

Problem 3: Linjär regression

Linjär regression är en metod för att modellera sambandet mellan en beroende variabel y och en eller flera oberoende variabler x genom en linjär funktion. Grundidén är att hitta den linje som bäst passar data genom att minimera summan av kvadrerade fel.

För enkel linjär regression har vi modellen:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, 2, \dots, n \quad (1)$$

där β_0 är intercept, β_1 är lutningen, och ε_i är feltermen som antas vara oberoende och normalfördelade med väntevärde 0 och varians σ^2 .

Minsta kvadratmetoden minimerar objektfunktionen:

$$Q(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \quad (2)$$

Genom att sätta partialderivatorna lika med noll får vi normalekvationerna, vilka kan lösas analytiskt för att ge skattningarna $\hat{\beta}_0$ och $\hat{\beta}_1$.

I vektorform kan modellen skrivas som:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \quad (3)$$

där \mathbf{X} är designmatrisen, $\boldsymbol{\beta}$ är parametervektorn, och lösningen blir:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} \quad (4)$$

Funktionen `tools.regress`

Filen `tools.py` innehåller funktionen `regress` som implementerar multipel linjär regression med minsta kvadratmetoden. Funktionen löser modellen:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \quad (5)$$

där \mathbf{y} är en vektor av observerade värden med form $(n,)$, \mathbf{X} är en matris av regressorer med form (n,p) , $\boldsymbol{\beta}$ är parametervektorn med form $(p,)$, och $\boldsymbol{\varepsilon}$ är en vektor av slumpmässiga fel med form $(n,)$.

Funktionen `regress` har följande egenskaper:

1. **QR-faktorisering:** Funktionen använder QR-faktorisering (`np.linalg.qr`) för att lösa normalekvationerna numeriskt stabilt, istället för att direkt invertera $\mathbf{X}^T \mathbf{X}$.
2. **NaN-hantering:** Alla rader som innehåller NaN-värden i antingen \mathbf{X} eller \mathbf{y} filtreras bort innan beräkningarna.
3. **Konfidensintervall:** Funktionen beräknar konfidensintervall för varje parameter baserat på t-fördelningen med $n - p$ frihetsgrader, där n är antalet observationer och p är antalet parametrar.
4. **Standardfel:** Standardfelet för varje parameter beräknas från diagonalen av $(\mathbf{R}^T \mathbf{R})^{-1}$, där \mathbf{R} kommer från QR-faktoriseringen.